

Quadric誤差指標を用いたサーフェス簡略化

Michael Garland* Paul S. Heckbert†

カーネギーメロン大学

要旨 コンピュータグラフィックスの多くの応用分野では、複雑で詳細なモデルが必要とされる。しかし、実際に必要となる詳細度はかなり変動しうる。処理時間を制御するために、過度に詳細なモデルの代わりに近似モデルを用いることがしばしば望ましい。我々は、多角形モデルの高品質な近似を高速に生成できるサーフェス簡略化アルゴリズムを開発した。このアルゴリズムは頂点对の反復的な縮約を用いてモデルを簡略化し、quadric行列を用いてサーフェス誤差近似を維持する。任意の頂点对（辺だけでなく）を縮約することにより、我々のアルゴリズムはモデルの非連結な領域を結合することができる。これにより、視覚的にも幾何誤差の観点からも、はるかに優れた近似が可能になる。位相的な結合を可能にするため、我々のシステムは非多様体サーフェスモデルもサポートする。我々のアルゴリズムは、このような多角形モデルの簡略版を生成する。本アルゴリズムは頂点对の反復的な縮約（辺縮約の一般化）に基づいている。アルゴリズムの進行に伴い、現在のモデルの各頂点において幾何誤差近似が維持される。この誤差近似はquadric行列を用いて表現される。本アルゴリズムの主な利点は以下の通りである。

- 効率性：本アルゴリズムは複雑なモデルを非常に高速に簡略化できる。例えば、我々の実装では70,000面のモデルから100面の近似モデルを15秒で生成できる。誤差近似も非常にコンパクトであり、頂点あたりわずか10個の浮動小数点数しか必要としない。
- 品質：本アルゴリズムによって生成される近似は、元のモデルに対して高い忠実度を維持する。モデルの主要な特徴は、大幅な簡略化を行った後でも保持される。
- 汎用性：他の多くのサーフェス簡略化アルゴリズムとは異なり、本アルゴリズムはモデルの非連結な領域同士を結合することができる。この処理を我々は「アグリゲーション (aggregation)」と呼ぶ。オブジェクトの位相の維持が重要でない場合、これは多数の非連結成分を持つモデルのより良い近似を可能にする。これにはまた、本アルゴリズムが非多様体¹モデルをサポートする必要がある。

CR分類： I.3.5 [コンピュータグラフィックス]：計算幾何学とオブジェクトモデリング—サーフェスおよびオブジェクト表現

キーワード： サーフェス簡略化、マルチ解像度モデリング、ペア縮約、詳細度 (LOD)、非多様体

1 序論

多くのコンピュータグラフィックスの応用では、説得力のあるリアリズムのレベルを維持するために複雑で詳細度の高いモデルが必要とされる。その結果、この詳細さへの要求に応えるため、モデルは非常に高い解像度で作成または取得されることが多い。しかし、そのようなモデルの完全な複雑さが常に必要とされるわけではなく、モデルの使用にかかる計算コストはその複雑さに直接関係するため、複雑なモデルの単純化版を持つことは有用である。当然ながら、我々はこれらの簡略化モデルを自動的に生成したいと考える。近年、サーフェス簡略化アルゴリズムに関する研究がこの目標に焦点を当ててきた。

この分野の他の多くの研究と同様に、我々は多角形モデルの簡略化に焦点を当てる。モデルは三角形のみから構成されると仮定するが、これは一般性を失わない。なぜなら、元のモデルのあらゆる多角形は前処理段階で三角形分割できるからである。より信頼性の高い結果を得るために、2つの面の角が1点で交わる場合、それらの面は空間的に偶然一致する2つの別々の頂点を使うのではなく、単一の頂点を共有するものとして定義すべきである。

多くの従来の簡略化アルゴリズムは、暗黙的または明示的に、入力サーフェスが多様体であり、かつそうあり続けるべきだと仮定してきた。我々はこの仮定を置かないことを強調したい。実際、アグリゲーションの過程は非多様体領域を定期的に生成することになる。

*garland@cs.cmu.edu；<http://www.cs.cmu.edu/~garland/>

†ph@cs.cmu.edu；<http://www.cs.cmu.edu/~ph/>

2.1 サーフェス簡略化

近年、サーフェス簡略化問題、およびそのより一般的な問題であるマルチ解像度モデリングは、ますます注目を集めている。これまでにいくつかの異なるアルゴリズムがサーフェス簡略化のために定式化されてきた。我々の研究に最も関連が深いアルゴリズムは、大きく3つのクラスに分類できる。




図1：辺縮約。強調表示された辺が1点に縮約される。網掛けされた三角形は退化し、縮約の過程で除去される。

頂点デシメーション (Vertex Decimation)

Schroederら [9] は、我々が「頂点デシメーション」と呼ぶアルゴリズムを記述している。この手法は反復的に削除する頂点を選択し、隣接する全ての面を除去し、生じた穴を再三角形分割する。SoucyとLaurendeau [10] は、より洗練されているが本質的に類似したアルゴリズムを記述している。これらは妥当な効率性と品質を提供するものの、我々の目的には必ずしも適していない。両手法とも頂点分類と再三角形分割のスキームを用いており、これは本質的に多様体サーフェスに限定されており、モデルの位相を注意深く維持する。これらは一部の領域では重要な特徴であるが、マルチ解像度レンダリングシステムにとっては制約となる。




図2：非辺縮約。非辺のペアが縮約されると、モデルの非連結な部分同士が結合される。破線は縮約される2つの頂点を示す。

頂点クラスターリング (Vertex Clustering)

RossignacとBorrel [8] によって記述されたアルゴリズムは、任意の多角形入力を処理できる数少ない手法の一つである。元のモデルの周りにバウンディング

グボックスが配置され、格子状に分割される。各セル内で、そのセルの頂点は単一の頂点にクラスタリングされ、モデルの面はそれに応じて更新される。この処理は非常に高速であり、モデルに劇的な位相変化をもたらすことができる。しかし、格子セルのサイズは幾何誤差の上限を与えるものの、出力の品質はしばしばかなり低い。さらに、面数は格子の次元によって間接的にしか決まらないため、特定の面数を持つ近似を構築することは難しい。生成される正確な近似は、周囲の格子に対する元モデルの正確な位置と向きにも依存する。この様な手法は、八分木 [6] のような適応的な格子構造を用いるように一般化することが容易である。これにより簡略化結果を改善できるが、それでも我々が望む品質と制御はサポートされない。

反復的辺縮約 (Iterative Edge Contraction)

辺を反復的に縮約することでモデルを簡略化するアルゴリズムがいくつか発表されている (図1参照)。これらのアルゴリズム間の本質的な違いは、縮約する辺をどのように選択するかにある。このようなアルゴリズムの代表例として、Hoppe [4, 3]、RonfardとRossignac [7]、Guéziec [2] の手法がある。これらのアルゴリズムはいずれも多様体サーフェス向けに設計されているようだが、辺縮約自体は非多様体サーフェスに対しても利用可能である。連続的な辺縮約を行うことで、オブジェクト内の穴を閉じることはできるが、非連結な領域を結合することはできない。

近似モデルが元のモデルからある距離以内に収まり、かつ位相が変化しないことが重要である場合、Cohenら [1] の「簡略化エンベロープ」手法を上記の簡略化アルゴリズムのいずれかと組み合わせて使用できる。モデルへの変更がエンベロープ内に制限される限り、大域的な誤差保証を維持できる。しかし、この手法はより強い誤差限界を提供する一方で、本質的に配向可能な多様体サーフェスに限定されており、モデルの位相を注意深く維持する。これもまた、レンダリング用の簡略化という目的にとっては制約となることが多い。

これまでに開発されたアルゴリズムのいずれも、我々が求める効率性、品質、汎用性の組み合わせを提供していない。頂点デシメーションアルゴリズムは我々の目的には不向きである。それらはモデルの位相を注意深く維持し、通常多様体形状を仮定する。頂点クラスタリングアルゴリズムは非常に汎用的で高速になり得るが、結果の制御が乏しく、品質が比較的低くなることもある。辺縮約アルゴリズムはアグリゲーションをサポートできない。

我々は、アグリゲーションと高品質な近似の両方をサポートするアルゴリズムを開発した。これは頂点クラスタリングの汎用性の多くを備えると同時に、反復縮約アルゴリズムの品質と制御性も併せ持つ。また、いくつかの高品質手法 [3] よりも高速な簡略化を可能にする。

3 ペア縮約によるデシメーション

我々の簡略化アルゴリズムは頂点对の反復的な縮約に基づいている。これは、従来の研究で用いられてきた反復的辺縮約手法を一般化したものである。ペア縮約は $(v_1, v_2) \rightarrow \bar{v}$ と記述され、頂点 v_1 と v_2 を新しい位置 $\bar{v}$ に移動させ、それらに接続していた全ての辺を v_1 に接続し直し、頂点 v_2 を削除する。その後、退化した辺や面はすべて除去される。縮約の効果は小さく、非常に局所的である。 (v_1, v_2) が辺である場合、1つ以上の面が除去される (図1参照)。そうでない場合、モデルの以前は分離していた2つの部分が $\bar{v}$ で結合される (図2参照)。

この縮約の概念は実際にはかなり一般的なものであり、頂点の集合を単一の頂点に縮約すること $(v_1, v_2, \dots, v_k) \rightarrow \bar{v}$ も表現できる。この一般化された縮約の形式は、ペア縮約だけでなく、頂点クラスタリングのようなより一般的な操作も表現できる。しかし、我々のアルゴリズムでは、これが最も細粒度の縮約操作であるため、ペア縮約をアトミックな操作として採用する。

初期モデル M_n から始めて、簡略化の目標が満たされるまで一連のペア縮約が適用され、最終的な近似モデル M_g が生成される。各縮約は現在のモデルへの局所的な増分的変更に対応するため、本アルゴリズムは実際には一連のモデル $M_n, M_{n-1}, \dots, M_g$ を生成する。したがって、1回の実行で多数の近似モデル、あるいはプログレッシブメッシュ [3] のようなマルチ解像度表現を生成できる。

3.1 アグリゲーション

一般化された頂点对の縮約を利用することで得られる主な利点は、モデルの以前は非連結だった領域を結合できるアルゴリズムの能力である。潜在的な副次的利点としては、アルゴリズムが元のモデルのメッシュ接続性に対して感度が低くなることが挙げられる。実際に2つの面が重複した頂点で接している場合、その頂点对を縮約することで元のメッシュのこの欠陥が修復される。



図3：左は、密に配置された100個の立方体からなる規則的な格子。中央は、辺縮約のみを用いて構築した近似で、許容できないほどの断片化を示している。右は、より一般的なペア縮約を用いてアグリゲーションを実現した結果で、元のモデルにはるかに近い近似となっている。

レンダリングのような一部の応用では、位相よりも全体的な形状の方が重要である場合がある。図3に示すような、規則的な格子状に密に配置された100個の立方体からなる形状を考える。この左側のモデルについて、遠距離からのレンダリング用の近似を構築したいとする。辺縮約に基づくアルゴリズムはオブジェクト内の穴を閉じることはできるが、非連結成分を結合することは決してできない。辺縮約のみを用いるアルゴリズムでは、中央のモデルのように、個々の構成要素が個別に何も無い状態にまで簡略化されてしまう。ペア縮約を用いることで、右側のモデルのように個々の構成要素を単一のオブジェクトに統合できる。その結果、はるかに忠実度の高い近似が得られる。

アグリゲーションを許容することは、非多様体サーフェスのサポートも必要とする。2つの別々の領域が結合される瞬間には、非多様体領域が生成される可能性が非常に高い。縮約が実行できる種類の操作を著しく制限することなく、縮約が決して非多様体領域を生成しないことを保証するには、多大な注意と労力が必要となるだろう。

3.2 ペアの選択

我々は初期化時に有効なペアの集合を選択し、アルゴリズムの実行中はこれらのペアのみを考慮することにした。この決定は、良い近似においては点が元の位置から大きく移動しないという仮定に基づいている。

ペア (v_1, v_2) が縮約のための有効なペアであるとは、以下のいずれかを満たす場合をいう。

1. (v_1, v_2) が辺である、または

2. $\|v_1 - v_2\| < t$ (t はしきい値パラメータ)

しきい値 $t = 0$ を用いると、単純な辺縮約アルゴリズムになる。しきい値を大きくすると、非連結な頂点同士をペアにできるようになる。当然ながら、このしきい値は注意深く選ぶ必要がある。値が大きすぎると、モデルの大きく離れた部分同士が結合されてしまう可能性があり、これはおそらく望ましくないうえ、 $O(n^2)$ 個のペアが生成されるおそれもある。

反復的な縮約の過程で、有効なペアの集合を追跡する必要がある。各頂点には、それが属するペアの集合を関連付ける。縮約 $(v_1, v_2) \rightarrow \bar{v}$ を実行する際、 v_1 は v_2 に連結していた全ての辺を獲得するだけでなく、 v_2 のペア集合をも自身の集合に統合する。有効なペア内の v_2 の全ての出現は v_1 に置き換えられ、重複するペアは除去される。

残る唯一の問題は、誤差指標を構成する初期のQ行列をどのように計算するかである。

4 Quadricによる誤差の近似

ある反復において実行すべき縮約を選択するためには、縮約のコストという概念が必要になる。このコストを定義するために、我々は各頂点における誤差を特徴づけようと試みる。そのために、各頂点にQという対称な 4×4 行列を対応させ、頂点 $v = [v_x \ v_y \ v_z \ 1]^T$ における誤差を二次形式 $\Delta(v) = v^T Q v$ として定義する。この初期行列がどのように構成されるかは第5節で説明する。水準面 $\Delta(v) = \varepsilon$ 、すなわちQに関する誤差が ε であるすべての点の集合は、quadric曲面であることを注意されたい。

与えられた縮約 $(v_1, v_2) \rightarrow \bar{v}$ に対して、 $\bar{v}$ における誤差を近似する新しい行列 $\bar{Q}$ を導出しなければならない。我々は単純な加算則 $\bar{Q} = Q_1 + Q_2$ を採用することにした。

縮約 $(v_1, v_2) \rightarrow \bar{v}$ を実行するには、 $\bar{v}$ の位置も選ばなければならない。単純な方式としては、 v_1, v_2 、または $(v_1+v_2)/2$ のうち、 $\Delta(\bar{v})$ の値が最も小さくなるものを選択する方法が考えられる。しかし、 $\Delta(\bar{v})$ を最小化する位置を $\bar{v}$ として求められればより望ましい。誤差関数 Δ は二次形式であるため、その最小値を求めることは線形問題となる。したがって、 $\partial \Delta / \partial x = \partial \Delta / \partial y = \partial \Delta / \partial z = 0$ を解くことで $\bar{v}$ を求める。これは以下の式を解くことと等価である。

$$\begin{bmatrix} q_{11} & q_{12} & q_{13} & q_{14} & q_{12} & q_{22} & q_{23} & q_{24} & q_{13} & q_{23} & q_{33} & q_{34} & 0 & 0 & 0 & 1 \end{bmatrix} \bar{v} = \begin{bmatrix} 0 & 0 & 0 & 1 \end{bmatrix}^T$$

行列の最下行が空白なのは、 $\bar{v}$ が同次ベクトルであり、そのw成分が常に1であるためである。この行列が可逆であると仮定すると、次式が得られる。

$$\bar{v} = \begin{bmatrix} q_{11} & q_{12} & q_{13} & q_{14} & q_{12} & q_{22} & q_{23} & q_{24} & q_{13} & q_{23} & q_{33} & q_{34} & 0 & 0 & 0 & 1 \end{bmatrix}^{-1} \begin{bmatrix} 0 & 0 & 0 & 1 \end{bmatrix}^T \dots\dots (式1)$$

この行列が可逆でない場合は、線分 $v_1 v_2$ 上で最適な頂点を探すことを試みる。それも失敗した場合は、端点と中点の中から $\bar{v}$ を選ぶ方式にフォールバックする。

4.1 アルゴリズムの要約

我々の簡略化アルゴリズムは、ペア縮約と誤差quadricを中心に構築されている。現行の実装では、頂点・辺・面がすべて明示的に表現され互いに連結された隣接グラフ構造を用いてモデルを表現する。有効なペアの集合を追跡するために、各頂点はそれが属するペアのリストを保持する。アルゴリズム自体は次のように要約できる。

1. すべての初期頂点についてQ行列を計算する。
2. すべての有効なペアを選択する。
3. 各有効なペア (v_1, v_2) について最適な縮約先 $\bar{v}$ を計算する。この目標頂点の誤差 $\bar{v}^T(Q_1+Q_2)\bar{v}$ が、そのペアを縮約するコストとなる。
4. 全ペアをコストをキーとしたヒープに配置し、最小コストのペアを先頭にする。
5. ヒープから最小コストのペア (v_1, v_2) を反復的に取り出し、そのペアを縮約し、 v_1 を含むすべての有効なペアのコストを更新する。



図4：本アルゴリズムを用いて生成された近似のシーケンス。左端の元モデルは5,804面。右方向の近似はそれぞれ994、532、248、64面。角や蹄のような特徴は、多くの簡略化を経ても存在し続けることに注目されたい。極端に低い詳細度になって初めて、それらは消え始める。

5 誤差Quadricの導出

誤差quadricを構成するには、幾何誤差を特徴づけるためのヒューリスティックを選ぶ必要がある。我々はRonfardとRossignac [7] が示したものとかなり類似したヒューリスティックを採用した。[7] にならい、元のモデルにおいて各頂点は平面の集合の交わりの解、すなわちその頂点で交わる三角形の平面群の交点であることに着目できる。各頂点に平面の集合を対応させ、その頂点の誤差をこの集合に対する二乗距離の和として次のように定義できる。

$$\Delta(v) = \Delta([v_x \ v_y \ v_z \ 1]^T) = \sum_{\{p \in \text{planes}(v)\}} (p^T v)^2 \dots\dots (式2)$$

ここで $p = [a \ b \ c \ d]^T$ は方程式 $ax + by + cz + d = 0$ ($a^2 + b^2 + c^2 = 1$) で定義される平面を表す。この近似誤差指標は [7] と類似しているが、我々は平面集合に対して最大値ではなく総和を用いている点異なる。ある頂点における平面の集合は、その頂点で交わる三角形の平面群として初期化される。もしこれらの平面集合を[7]のように明示的に追跡するならば、縮約 $(v_1, v_2) \rightarrow \bar{v}$ の後、規則 $\text{planes}(\bar{v}) = \text{planes}(v_1) \cup \text{planes}(v_2)$ を用いて平面を伝播させる必要がある。これは、簡略化が進んでも減少しないかなりの量のストレージを必要とする可能性がある。

式(2)で与えられる誤差指標は、次のように二次形式として書き直せる。

$$\Delta(v) = \sum (v^T p) (p^T v) = v^T \left(\sum p p^T \right) v = v^T \left(\sum K_p \right) v \quad (p \in \text{planes}(v))$$

ここで K_p は次の行列である。

$$K_p = p p^T = \begin{bmatrix} a^2 & ab & ac & ad & ab & b^2 & bc & bd & ac & bc & c^2 & cd & ad & bd & cd & d^2 \end{bmatrix}$$

この基本誤差quadric K_p を用いれば、空間上の任意の点から平面pまでの二乗距離を求めることができる。これらの基本quadricを足し合わせることで、平面の集合全体を単一の行列Qで表現できる。我々は平面の集合和 $(\text{planes}(v_1) \cup \text{planes}(v_2))$ を計算する代わりに、2つのquadric (Q_1+Q_2) を単純に加算することで、平面集合を暗黙的に追跡している。元の指標において Q_1 と Q_2 が表す集合が互いに素であれば、このquadricの加算は集合和と等価になる。重なる

りがある場合、1つの平面が複数回カウントされることがある。しかし、各平面はその定義三角形の頂点にしか分配されないため、いかなる単一の平面も最大3回しかカウントされない。これはある程度の誤差測定の不正確さをもたらす可能性があるが、大きな利点がある。すなわち、平面集合を追跡するために必要な記憶容量は、単一の4×4対称行列（浮動小数点数10個）を保持するだけで済み、近似の更新コストもそのような行列を2つ加算するだけで済む。追加のストレージを許容するならば、包除原理を用いてこの多重カウントを排除することも可能である。

このように、我々のペア縮約アルゴリズムに必要な初期Q行列を計算するには、各頂点とその頂点で交わる三角形群の平面を累積すればよい。各頂点について、この平面集合はいくつかの基本誤差quadric K_p を定義する。この頂点の誤差quadric Qは、これらの基本quadricの総和である。各頂点はその頂点に接する全ての三角形の平面上に存在するため、各頂点の初期誤差推定値は0になることに注意されたい。

5.1 幾何学的解釈

後述するように、我々の平面ベースの誤差quadricはかなり高品質な近似を生成する。さらに、これらは有用な幾何学的意味³も持っている。

これらのquadricの水準面は、ほとんどの場合楕円体になる。ある種の状況では、水準面が退化することがある。例えば、平行な平面群（平坦なサーフェス領域の周囲など）は2枚の平行な平面からなる水準面を生成し、1本の直線に平行な平面群（線状のサーフェスの折れ目の周囲など）は円柱状の水準面を生成する。最適な頂点位置を求めるために用いる行列（式1）は、水準面が非退化な楕円体である限り可逆となる。この場合、vは楕円体の中心に位置することになる。

6 追加の詳細

ここまで概説した一般的なアルゴリズムは、ほとんどのモデルに対して良好に機能する。しかし、特定の種類のモデル、特に開いた境界を持つ平面的なモデルに対して性能を向上させる、いくつかの重要な拡張がある。

境界の保存

先に導出した誤差quadricは、開いた境界に対する配慮を一切行っていない。地形の高さフィールドのようなモデルでは、形状を簡略化しつつ境界曲線を保存する必要がある。また、離散的な色の不連続性を保存したい場合もある。このような場合、我々はまず各辺を「通常」または「不連続」のいずれかとしてラベル付けする。特定の不連続辺を囲む各面について、その辺を通る垂直な平面を生成する。これらの制約平面はquadricに変換され、大きなペナルティ係数で重み付けされた上で、その辺の端点の初期quadricに加算される。この手法は非常にうまく機能することがわかっている。

メッシュの反転の防止

ペア縮約は、縮約領域内の面の向きを必ずしも保持しない。例えば、辺を縮約することで隣接するいくつかの面が互いに重なり合うように折れ曲がってしまう可能性がある。通常、この種のメッシュ反転は避けるべきである。我々は他の研究（例えば[7]）とほぼ同じ方式を用いる。ある縮約の候補を検討する際、縮約前後で各隣接面の法線を比較する。法線が反転する場合、その縮約には重いペナルティを課すか、あるいは許可しないようにする。

6.1 近似の評価

本アルゴリズムが生成する近似の品質を評価するために、アルゴリズム自体が用いるヒューリスティックな誤差測定よりもやや厳密な誤差測定が必要である。我々は、近似モデルと元のモデルとの平均二乗距離を測定する指標を採用した。これはHoppeら [4] が用いたE_{dist} エネルギー項に非常に近いものである。簡略化モデル M_i の近似誤差 E_i = E(M_n, M_i) を次のように定義する。

$$E_i = 1 / (|X_n| + |X_i|) \left(\sum \{vEX_n\} d^2(v, M_i) + \sum \{vEX_i\} d^2(v, M_n) \right)$$

ここでX_nとX_iはそれぞれモデルM_nとM_iの表面上でサンプリングされた点の集合である。距離 d(v, M) = min_{p∈M} || v-p || は、点vからMの最も近い面までの最小距離である（|| · || は通常のユークリッドベクトル長演算子）。この指標は評価目的のみに用いており、実際のアルゴリズムには一切関与しない。

7 結果

モデル	面数	t	初期化(s)	簡略化(s)
Bunny	69,451	0	3.3	12.0
Crater Lake	199,114	0	10.6	36.0
Cow	5,804	0	0.22	0.69
Cube Grid	1,200	0.12	0.25	0.17
Foot	4,204	0	0.16	0.41
Foot	4,204	0.318	0.43	0.76

図5：実行時間の例。すべてのデータは、指定モデルの10面近似を作成するのに要した時間を示す。初期化時間には有効なペアの選択、初期誤差行列の計算、縮約先の選択が含まれる。簡略化時間はペアの反復的な縮約を含む。

面数 (i)	固定(E _i)	最適(E _i)	削減率
10	0.0062	0.0054	13.4%
100	0.00032	0.00025	21.7%
500	2.4e-05	1.3e-05	47.6%
1000	5.7e-06	3.4e-06	40.3%
2000	1.2e-06	7.9e-07	32.4%
3000	3.6e-07	2.6e-07	28.2%

図6：最適な頂点配置の効果。端点や中点の中から固定的に選ぶのではなく、最適な位置を選ぶことで近似誤差を大幅に削減できる。近似はt=0を用いた牛モデルのもの。

我々のアルゴリズムは、かなり短時間で高忠実度の近似を生成できる。図5は、本論文で示したモデルを用いた現行実装の実行時間⁴をまとめたものである。図4は本アルゴリズムによって生成された近似の一連のサンプルを示している。この牛のモデル全体のシーケンスは約1秒で構築された。角や蹄のような特徴は、多くの簡略化を経ても認識可能なままであることに注目されたい。極端に低い詳細度になって初めて、それらは消え始める。

先に述べたように、我々のアルゴリズムは縮約後の頂点位置の最適化を試みる。図6は、代表的なモデル（図4の牛モデル）に対するこの方針の効果をまとめたものである。極端に低い詳細度では、その効果は控えめである。しかし、より妥当な詳細度レベルでは効果は顕著であり、最適な頂点配置により全体誤差を最大50%削減できる。我々の実験では、最適な頂点配置を用いることで、より整った形状のメッシュが生成される傾向があることもわかった。




図8：69,451三角形からなる元のbunnyモデル。以下の近似と同様にフラットシェーディングでレンダリング。



図9：1,000三角形のみを用いた近似（15秒で生成）。



図10：100三角形のみを用いた近似（15秒で生成）。




図11：1,000面近似。各頂点の誤差楕円体を緑色で表示。




図12：Crater Lakeの地形モデル（199,114面）。



図13：999面に簡略化したモデル（46秒）。

図8～13は、本アルゴリズムのより大規模なモデルに対する性能を示している。図9は元モデルの大幅な簡略化（1.4%）を表しているが、元モデルの主要な詳細がすべて残っていることに注目されたい。特に、耳の内側の輪郭や後ろ脚周りの大きな輪郭が保存されていることに注目されたい。図10はさらに劇的な近似、すなわち元のサイズの100面（0.14%）を示している。モデルの詳細のほとんどは消えているが、オブジェクトの基本構造は依然として保たれており、頭部、脚、尾、耳といった主要な特徴は、高度に簡略化されているとはいえ、すべて確認できる。図12は非常に密にテッセレーションされた地形モデルを示し、図13は高度に簡略化されたバージョンを示す。地形の小規模なテクスチャはほぼ消失しているが、地形の基本的な特徴はすべて残っている。開いた境界も適切に保存されていることに注目されたい。先に述べた境界制約がなければ、境界は著しく損なわれていたであろう。

図11は、簡略化の過程で蓄積された誤差quadricの性質を示している。各頂点について $v^T Q v = \epsilon$ で表される水準面が示されている。それぞれの水準面は対応する頂点を中心とした楕円体である。これらの楕円体の解釈は、頂点はその楕円体内のどこに移動しても ϵ より小さい誤差しか持たないということである。これらの楕円体の重要な特徴は、モデルサーフェスの形状に非常によく適合することである。後ろ脚の中央のような主に平面的な領域では大きく平たくなり、耳を通る輪郭や脚の底に沿った輪郭のような不連続線に沿っては引き伸ばされている。ある意味で、これらの楕円体はその頂点周りの局所的なサーフェス形状に関する情報を蓄積していると考えることができる。




図14：原本。人間の左足の骨（4,204面）。多数の独立した骨のセグメントに注目。




図15：一様な頂点クラスタリング。262面近似（ $11 \times 4 \times 4$ 格子）。無差別な結合が近似品質を損なっている。




図16：辺縮約。250面近似。つま先の先端の骨セグメントが消失し、つま先が足の中へ後退しているように見える。




図17：ペア縮約。250面近似（ $t=0.318$ ）。つま先はより大きな単一の部品に統合されている。後退のアーティファクトなし。このモデルには61個の非多様体辺が含まれる。




図18：図16に示す近似の頂点における誤差quadricの水準面。




図19：初期化時に有効として選択されたペア（図17用）。赤いペアは辺、緑のペアは非辺。

図14～17は、ペア縮約によるアグリゲーションがもたらす真の利点を示している。元のモデルは人間の左足の骨から構成される。多数の独立した骨のセグメントがあり、その一部は互いに貫入している（モデル再構成上の誤りであることは明らかである）。3種類の近似が比較されている。すなわち、一様な頂点クラスタリングで構築したもの、辺縮約のみで構築したもの、そしてペア縮約で構築したものである。辺縮約のみを用いた場合、つま先の先端の小さなセグメントが単一の点に潰れてしまい、つま先が徐々に足の中へ後退していくような印象を与える。一方、より一般的なペア縮約を用いると、独立した骨のセグメントを結合できる。図17に見られるように、つま先は単一の長いセグメントへと統合されている。図19は、初期化時に有効として選択されたペアの一部を示している。それらが骨セグメント間の隙間をどのように橋渡ししているかに注目されたい。最後に、図18は簡略化過程で蓄積された誤差quadricの水準面

の別の図（図16に示すモデルのもの）を示す。

アグリゲーションの利点は視覚的なものだけではない。アグリゲーションは客観的に見てもより低い近似誤差を生み出すことができる。図7は、足モデル（図14）の250面近似における様々な t の値に対する誤差 E_{250} を示している。かなり広い範囲の値が、辺縮約のみ（ $t=0$ ）による近似よりも客観的に優れた近似を生成する。しかし、 t を大きくすることが常に近似を改善するとは限らないことに注意されたい。これは我々のquadric誤差指標の性質によるものである。局所的には、平面集合までの距離は面集合までの距離の妥当な近似となる。しかし、平面は無限の広がりを持つのに対し面はそうではないため、遠くへ移動するにつれて誤差指標の信頼性は低下していく。




図7：ペアしきい値の影響。足モデル（図14）の250面近似について、 t の関数として近似誤差 E_{250} を示す。アグリゲーションを伴うペア縮約は近似誤差を大幅に削減できる。

8 考察

本アルゴリズムは、従来のアルゴリズムには見られなかった効率性・品質・汎用性の組み合わせを提供する。他のいくつかのアルゴリズムは我々のものより高速であったり、より高品質な近似を生成したりするが、それらは通常この3つの領域すべてで我々のアルゴリズムの能力に匹敵することはない。任意の多角形モデルを簡略化できる唯一のアルゴリズムである頂点クラスタリング [8] は、信頼性の高い高品質な近似を生成しない。利用可能な他の高品質手法 [2, 7, 3] はいずれもアグリゲーションをサポートしない。[2]と[3]はいずれも我々のアルゴリズムよりかなり時間がかかるようである。[7]の結果は、我々が非常に類似した誤差近似を用いているため、我々自身の結果に最も似ている。しかし、我々のシステムは平面集合を追跡するためのより効率的な手段を用いており、境界保存のようないくつかの拡張機能も組み込んでいる。

我々のアルゴリズムには改善の余地がまだ残されている。我々は有効なペアを選択するためにかなり単純な方式を用いた。より洗練された適応的な方式によって、より良い結果が得られる可能性は十分にある。我々は色などのサーフェス属性の問題には取り組んでいない。一つの可能な解決策は、各頂点を(x, y, z, r, g, b)のベクトルとして扱い、 7×7 のquadricを構築して簡略化することである。これはうまく機能すると考えられるが、サイズと複雑さが増すため、基本アルゴリズムほど魅力的ではない。

本アルゴリズムは概して良好に機能するが、明確な弱点もいくつかある。まず、先述の通り、誤差を平面集合までの距離として測定する手法は、適切な局所的近傍でのみうまく機能する。次に、quadricに蓄積された情報は本質的に暗黙的なものであり、これが時に問題となることがある。例えば、2つの立方体を結合し、もはや存在しなくなった内部の面に関連する平面を除去したいとする。どの面が不要になったかを一般に判定することは困難であるうえ、quadricから該当する平面を確実に除去する明確な方法も存在しない。その結果、我々のアルゴリズムは、望むほど良好にはアグリゲーションを伴う簡略化を行えない場合がある。

9 結論

我々は、多角形モデルの高忠実度な近似を高速に生成できるサーフェス簡略化アルゴリズムを記述した。本アルゴリズムは反復的なペア縮約を用いてモデルを簡略化し、quadric誤差指標を用いてモデルが簡略化される過程での近似誤差を追跡する。最終的な頂点に格納されたquadricは、サーフェスの全体的な形状を特徴づけるためにも利用できる。

我々のアルゴリズムは、かなり高品質な結果を維持しつつ、モデルの非連結な部分を結合する能力を持つ。従来のほとんどのアルゴリズムが本質的に多様体サーフェスに限定されているのに対し、我々のシステムは非多様体オブジェクトの取り扱いと簡略化を十分に行うことができる。最後に、我々のアルゴリズムは、頂点クラスタリング [8] のような非常に高速だが低品質な手法と、メッシュ最適化 [3] のような非常に低速だが高品質な手法との間の有用な中間的な位置づけを提供する。

¹ 多様体 (manifold) とは、その表面上のすべての点の無限小近傍が位相的に円板 (境界を持つ多様体の場合は半円板) と同等であるようなサーフェスをいう。

³ KalvinとTaylor [5] は平面集合を表現するためにquadricを同様の方法で用いている。彼らは、ある許容誤差内で点集合に適合する平面集合を追跡しており、有効な近似平面の集合を表現するために平面空間における楕円体を用いていた。

⁴ このデータは195MHzのR10000プロセッサと128Mバイトのメモリを搭載したSGI Indigo2上で収集された。

参考文献

1. Jonathan Cohen, Amitabh Varshney, Dinesh Manocha, Greg Turk, Hans Weber, Pankaj Agarwal, Frederick Brooks, William Wright. Simplification

- envelopes. *SIGGRAPH '96 Proc.*, pp.119–128, 1996.
2. André Guéziec. Surface simplification with variable tolerance. *Second Annual Intl. Symp. on Medical Robotics and Computer Assisted Surgery (MRCAS '95)*, pp.132–139, 1995.
 3. Hugues Hoppe. Progressive meshes. *SIGGRAPH '96 Proc.*, pp.99–108, 1996.
 4. Hugues Hoppe, Tony DeRose, Tom Duchamp, John McDonald, Werner Stuetzle. Mesh optimization. *SIGGRAPH '93 Proc.*, pp.19–26, 1993.
 5. Alan D. Kalvin, Russell H. Taylor. Surfaces: polygonal mesh simplification with bounded error. *IEEE Computer Graphics and Appl.*, 16(3), 1996.
 5. David Luebke, Carl Erikson. View-dependent simplification of arbitrary polygonal environments. *SIGGRAPH '97 Proc.*, 1997.
 7. Rémi Ronfard, Jarek Rossignac. Full-range approximation of triangulated polyhedra. *Computer Graphics Forum*, 15(3), 1996.
 3. Jarek Rossignac, Paul Borrel. Multi-resolution 3D approximations for rendering complex scenes. *Modeling in Computer Graphics: Methods and Applications*, pp.455–465, 1993.
 9. William J. Schroeder, Jonathan A. Zarge, William E. Lorensen. Decimation of triangle meshes. *Computer Graphics (SIGGRAPH '92 Proc.)*, 26(2):65–70, 1992.
 0. Marc Soucy, Denis Laurendeau. Multiresolution surface modeling based on hierarchical triangulation. *Computer Vision and Image Understanding*, 63(1):1–14, 1996.